

1. Phương pháp xây dựng Chatbot RAG

1.1. Quy trình xây dựng Knowledge Base

Xây dựng hệ thống chatbot có thể trả lời chính xác các câu hỏi liên quan đến tuyển sinh và đào tạo tại Trường Đại học Công Thương TP.HCM, bước đầu tiên và quan trọng nhất là xây dựng một kho tri thức (knowledge base) đầy đủ, chính xác và có cấu trúc rõ ràng. Quy trình xây dựng knowledge base được nhóm thực hiện qua bốn bước tuần tự:

- **Bước 1: Thu thập dữ liệu (Data Collection)**

Nhóm tiến hành thu thập thông tin từ các nguồn chính thức của trường, bao gồm đề án tuyển sinh các năm gần nhất, web tuyển sinh chính thức, thông tin chương trình đào tạo của từng ngành, và các tài liệu công khai khác liên quan đến điều kiện xét tuyển, tổ hợp môn thi, điểm chuẩn các năm trước, chỉ tiêu xét tuyển, học phí, và cơ hội nghề nghiệp sau tốt nghiệp. Việc chỉ sử dụng thông tin chính thức là yêu cầu bắt buộc nhằm đảm bảo độ tin cậy của toàn bộ hệ thống ở các bước sau.

- **Bước 2: Làm sạch dữ liệu (Data Cleaning)**

Dữ liệu thô thu thập được, đặc biệt nếu trích xuất từ file PDF hoặc trang web, thường chứa nhiều nhiễu không cần thiết như kí tự định dạng thừa, bảng biểu bị lỗi cấu trúc khi trích xuất, tiêu đề, chân trang bị lặp lại hoặc thông tin đã lỗi thời. Bước làm sạch nhằm loại bỏ các yếu tố nhiễu này, đồng thời chuẩn hoá định dạng văn bản (thống nhất cách viết tên ngành, mã tổ hợp, đơn vị đo lường) để đảm bảo chất lượng đầu vào cho các bước xử lý tiếp theo.


- **Bước 3: Chia đoạn văn bản (Chunking)**

Áp dụng chiến lược chunking theo ngữ nghĩa (semantic chunking), dữ liệu sau khi làm sạch được chia thành các đoạn văn bản có ý nghĩa hoàn chỉnh, tương ứng với từng đơn vị thông tin cụ thể, ví dụ mỗi ngành học là

một chunk riêng biệt, mỗi mục thông tin (điều kiện xét tuyển, học phí, chương trình đào tạo) trong một ngành cũng được tách thành các chunk

- **Bước 4: Embedding và lưu trữ (Embedding & Storage)**

Mỗi chunk văn bản sau khi hoàn thiện được chuyển đổi thành vector thông qua mô hình embedding của google, kèm theo metadata mô tả (tên ngành, loại thông tin, nguồn trích dẫn), sau đó được lưu trữ vào Chroma Vector DB.



1.2. Pipeline xử lý truy hồi và sinh câu trả lời

Sau khi knowledge base đã được xây dựng hoàn chỉnh, pipeline xử lý một câu hỏi tự nhiên từ người dùng thực tế được thực hiện theo quy trình sau, kế thừa và cụ thể hoá RAG cơ bản:

- Khi người dùng đặt câu hỏi, hệ thống backend nhận câu hỏi và chuyển đến bước truy hồi (retrieval): câu hỏi được embedding bằng cùng mô hình đã dùng (text-embedding-004) cho knowledge base, sau đó so khớp độ tương đồng với toàn bộ vector đã lưu trong Chroma để lấy ra top-k đoạn văn bản liên quan nhất. Các đoạn văn bản này, cùng với metadata nguồn đi kèm, được đưa vào bước ghép ngữ cảnh (prompt augmentation)

theo template đã được thiết kế ở phần Prompt Engineering cho trích dẫn nguồn, bao gồm chỉ dẫn hệ thống, ngữ cảnh truy hồi được và câu hỏi gốc. Cuối cùng, prompt hoàn chỉnh được gửi đến mô hình Gemini để sinh câu trả lời (Generation), kết quả trả về được kiểm tra định dạng trích dẫn trước khi hiển thị cho người dùng.

[Hình ảnh cần bổ sung: Sơ đồ pipeline đầy đủ, có thể ghép chung với sơ đồ RAG cơ bản đã có ở Chương 2 nhưng bổ sung chi tiết cụ thể của hệ thống (tên thư viện, tên model dùng thật)]

1.3. Thiết kế bộ câu hỏi kiểm thử (Test Set)

Để có cơ sở đánh giá chất lượng hệ thống một cách khách quan trước khi đưa vào sử dụng, nhóm xây dựng một bộ câu hỏi kiểm thử mẫu, bao phủ 3 nhóm nội dung chính mà người dùng thực tế (học sinh, phụ huynh) thường quan tâm khi tìm hiểu thông tin tuyển sinh.

- **Nhóm 1: Câu hỏi về điểm chuẩn**

Các câu hỏi liên quan đến điểm chuẩn trúng tuyển của các ngành trong những năm gần nhất, ví dụ: “Điểm chuẩn ngành Công nghệ thông tin năm 2025 là bao nhiêu?”, “Ngành nào có điểm chuẩn thấp nhất năm ngoái?”. Đây là nhóm câu hỏi đòi hỏi độ chính xác về mặt số liệu, vì sai lệch dù nhỏ cũng ảnh hưởng trực tiếp đến quyết định của người dùng.

- **Nhóm 2: Câu hỏi về chương trình đào tạo**

Các câu hỏi về nội dung cấu trúc chương trình học, thời gian đào tạo, hoặc các môn học chính của từng ngành, ví dụ: “Chương trình đào tạo ngành CNTT kéo dài bao lâu?”, “Ngành Quản trị kinh doanh có những chuyên ngành nào?”.

- **Nhóm 3: Câu hỏi về cơ hội việc làm**

Các câu hỏi liên quan đến định hướng về nghiệp và cơ hội việc làm sau khi tốt nghiệp từng ngành, ví dụ: “Học ngành CNTT ra trường làm công

việc gì?”, “Ngành nào có cơ hội việc làm tốt nhất hiện nay ?”.

Đối với mỗi câu hỏi trong bộ kiểm thử, nhóm chuẩn bị sẵn câu trả lời chuẩn (ground truth) dựa trên thông tin xác thực từ knowledge base, làm cơ sở để so sánh và tính toán các chỉ số đánh giá (Faithfulness, Answer Relevancy, Context Precision / Recall).

[Hình ảnh cần bổ sung: Bảng ví dụ minh họa bộ câu hỏi kiểm thử — 3 cột: Câu hỏi, Nhóm nội dung, Câu trả lời chuẩn (ground truth) — mỗi nhóm 3-5 câu hỏi mẫu]